



## Projet 1 – automate. Clone de egrep avec support partiel des ERE.

BM Bui-Xuan

**Expression régulière (Regex) et la norme ERE :** Une expression régulière est une représentation d'un langage algébrique reconnaissable par automate fini déterministe, dans le sens de la théorie de langage formel. Nous considérerons uniquement les expressions régulières répondant à la norme ERE décrite sur la page suivante, que nous notons également Regex : <http://pubs.opengroup.org/onlinepubs/7908799/xbd/re.html>

**Recherche de motif par Regex :** Etant donné un fichier textuel comprenant  $l$  lignes, le problème de recherche de motif contenu dans le fichier peut être décomposé en exécutant  $l$  fois la recherche du même motif, sur chacune des  $l$  lignes du fichier. Le but général de ce projet est d'implémenter une telle recherche de motif. Plusieurs stratégies peuvent être prises en compte. Pendant les séances de cours, nous proposons deux stratégies majeures, rappelées ci-après. Cependant, il est libre à chaque groupe d'implémenter ses propres stratégies, à condition que ce qui est décrit dans le rapport est en concordance avec ce qui est implémenté. Les deux stratégies de recherche de motif proposées dans les première et troisième séances de l'UE sont les suivantes.

- Si le motif n'est pas réduit à une suite de concaténations, nous allons d'abord transformer le motif en un arbre de syntaxe (1) puis en un automate fini non-déterministe avec  $\epsilon$ -transitions selon la méthode Aho-Ullman (2) puis en un automate fini déterministe avec la méthode des sous-ensembles (3) puis en un automate équivalent avec un nombre minimum d'états (4) et enfin l'automate est utilisé pour tester si un suffixe d'une ligne du fichier textuel donné initialement est reconnaissable par cet automate (5). Il s'agit de la Séance 1 de l'UE.
- Si le motif est réduit à une suite de concaténations, il s'agit de la recherche d'un facteur dans une chaîne de caractères : nous pouvons alors utiliser l'algorithme Knuth-Morris-Pratt (KMP) à la place de la machine de guerre décrite ci-dessus. Il s'agit de la Séance 3 de l'UE.

**Analyse de la performance de la recherche :** Chaque groupe est libre de choisir ses stratégies de recherche de motif<sup>1</sup>, à condition que la recherche de motif donne le même résultat que celui retourné par la commande `egrep`<sup>2</sup>. Si un motif est ciblé afin d'accélérer le calcul, comme le cas de KMP, il convient de bien expliquer la méthode utilisée, ainsi que de faire confronter son implémentation avec la méthode de la Séance 1, voire confronter ses performances avec celles (finement optimisées) de la commande `egrep` elle-même.

ATTENTION : si on décide d'implémenter KMP (resp. le *P-trie/hastable/Bloom-filter* du *index table*), il faut tout de même l'expliquer dans le rapport, ainsi qu'inclure dans celui-ci les tests de performance de cette implémentation.

### 1 L'énoncé du projet 1 – moteur de recherche *offline, desktop*

Il s'agit de proposer un clone de la commande `egrep`. Cependant, certaines conventions de la norme ERE sont assez fastidieuses à venir complètement à bout. Nous allons nous restreindre aux éléments suivants : les parenthèses, l'alternative, la concaténation, l'opération étoile, le point (i.e. caractère universel), et la lettre ASCII. Un exemple de réponse de `egrep` est donné en Fig. 1.

Un effort particulier doit être mis sur la phase de test et celle de la rédaction du rapport. Il y aura ainsi deux notations distinctes pour le rendu de ce projet : une note pour la réalisation ( $\approx 50\%$ ); et une note pour le rapport ( $\approx 50\%$ ).

1. On peut notamment penser à construire par un précalcul, dont le résultat est enregistré dans un fichier-cache, une table des indices représentant la liste de tous les mots (du langage humain) apparaissant dans le fichier textuel (construction de type *forward indexing* des *tokens* du texte), puis optimiser la recherche dans ce fichier-cache par des structures d'accès rapide de type *P-tries*, *hashtables* ou autres *Bloom-filters*.

2. En clair, il faut implémenter au moins ce qui a été vu en Séance 1.

```

>>>> Oui maitres? <<<< egrep "S(algr)+on" 56667-0.txt
state--Sargon and Merodach-baladan--Sennacherib's attempt
under the Sargonids--The policies of encouragement and
that empire's expansion, and the vacillating policy of the Sargonids
to Sargon of Akkad; but that marked the extreme limit of Babylonian
Arabian coast. The fact that two thousand years later Sargon of
A: Sargon's quay-wall. B: Older moat-wall. C: Later moat-wall of
It is the work of Sargon of Assyria,[44] who states the object of
upon it."[45] The two walls of Sargon, which he here definitely names
the quay of Sargon,[46] which run from the old bank of the Euphrates
to the Ishtar Gate, precisely the two points mentioned in Sargon's
A: Sargon's quay-wall. B: Older moat-wall. C: Later moat-wall of
quay-walls, which succeeded that of Sargon. The three narrow walls
Sargon's earlier structure. That the less important Nimitti-Bél is not
in view of Sargon's earlier reference,
excavations. The discovery of Sargon's inscriptions proved that in
precisely the same way as Sargon refers to the Euphrates. The simplest
[Footnote 44: It was built by Sargon within the last five years of
Sargon of Akkad had already marched in their raid to the Mediterranean
Babylonian tradition as the most notable achievement of Sargon's reign;
for Sargon's invasion of Syria. In the late omen-literature, too, the
Sargon's army had secured the capture of Samaria, he was obliged to
Sargon and the Assyrian army before its walls. Merodach-baladan was
After the defeat of Shabaka and the Egyptians at Raphia, Sargon was
their appearance from the north and east. In fact, Sargon's conquest of
Sargon was able to turn his attention once more to Babylon, from
On Sargon's death in 705 B.C. the subject provinces of the empire
party, whose support his grandfather, Sargon, had secured,[43] In 668
Sargon's death formed a period of interregnum, though the Kings' List
fifteen hundred years before the birth of Sargon I., who is supposed
>>>> Oui maitres? <<<<

```

FIGURE 1 – Exemple de réponse de la commande Linux `egrep` prenant en entrée le RegEx `'S(algr)+on'` et le fichier textuel <http://www.gutenberg.org/files/56667/56667-0.txt>.

On veillera à expliciter les points suivants, pour chaque algorithme implémenté (y compris les algorithmes décrits pendant les séances de cours tels de ceux dans le livre Aho-Ullman, algorithme KMP, ou ceux qui ne sont pas décrits dans le cours liés à la recherche dans les *index tables*) :

- définition du problème et la structure de données utilisée.
- analyse et présentation théorique des algorithmes connus dans la littérature.
- argumentation concise appuyant toute appréciation, amélioration, ou critique à propos de ces algorithmes existants dans la littératures.
- partie test : méthode d'obtention des *testbeds*. Il est recommandé d'utiliser la base de Gutenberg disponible à l'adresse suivante : <http://www.gutenberg.org/>
- test de performance : mieux vaut privilégier les courbes, diagrammes bâton (moyenne + écart type) et diagrammes de fréquence, plutôt qu'exhiber les colonnes de chiffres sans fin...
- une discussion sur les résultats de test de performance est toujours la très bienvenue.
- conclusion et perspectives sur ce problème de recherche de motif dans un fichier textuel (a.k.a. le cas *offline* des moteurs de recherche).

Il est prudent d'avoir entre 5 et 10 pages pour un rapport avec un contenu moyen. La limitation formelle pour ce rapport est 12 pages. Il convient de bien respecter cette limitation : les pages 13+ ne seront pas lues !

Contraintes :

- A réaliser en binôme ou en individuel.
- Archiver la totalité du rendu en un seul fichier compressé contenant de la documentation (rapport  $\approx$  5-10 pages), un binaire et un README expliquant comment exécuter le binaire, le code source commenté, un Makefile (ou Apache Ant si Java), un répertoire contenant les instances de test, et tout ce dont on juge utile à la lecture du projet sans toute fois dépasser la dizaine de Méga-octet.
- Envoyer ce fichier à [buixuan@lip6.fr](mailto:buixuan@lip6.fr), 3 emails maximum par groupe. L'utilisation des hébergeurs en ligne (drive et compagnies) est strictement interdite. La nomination de préférence est `daar-projet-offline-NOM1-NOM2.piki`, où `piki` peut être un élément de  $\{tgz, zip, rar, 7z, etc\}$ . Ce format du nom de fichier est important pour un classement automatique des rendus de projet dans le pauvre PC de l'évaluateur des projets de l'UE...
- Deadline : 09 Octobre 2022, 23h59, cachet de serveur de messagerie faisant foi. Pénalité de retard : malus de  $2^{h/24}$  points pour  $h$  heures de retard.